

УНИВЕРСИТЕТ ИТМО
ФАКУЛЬТЕТ ПРОГРАММНОЙ ИНЖЕНЕРИИ
И КОМПЬЮТЕРНОЙ ТЕХНИКИ

Лабораторная работа №4

Нахождение коэффициентов линейной регрессии и СКО

(по дисциплине «Математическая статистика»)

Выполнили:

Лабин Макар Андреевич,
МатСтат 23.1, Р3231, 466449;
Снагин Станислав Максимович,
МатСтат 23.1, Р3215, 467525.

Проверила:

Танченко Юлия Валерьевна

г. Санкт-Петербург, Россия
2026

Содержание

1	Постановка задач	1
2	Выполнение работы	2
2.1	Линейная регрессия	2
2.2	Метод наименьших квадратов	2
2.3	Вычисление оценки МНК	4
2.4	Среднеквадратическое отклонение	5
2.5	Вычисление оценки СКО	5
2.6	График результата	6
3	Заключение	7

1 Постановка задач

В ходе лабораторной работы *по варианту №7* для линейной регрессии вида

$$f(x) = w_0 + w_1x + w_2x^2$$

будут выполнены следующие задачи:

1. Найти коэффициенты линейной регрессии *методом наименьших квадратов (МНК)*.
2. Вычислить среднеквадратическое отклонение (RMSE).
3. Изобразить на графике точки выборки (x, t) с графиком линейной регрессии.

Для анализа предоставлена следующая выборка:

№	x	t	№	x	t	№	x	t	№	x	t
1	1.0	2.0	6	1.5	1.3	11	2.0	1.0	16	2.5	1.3
2	1.1	1.7	7	1.6	1.1	12	2.1	1.1	17	2.6	1.2
3	1.2	1.8	8	1.7	1.2	13	2.2	1.0	18	2.7	1.5
4	1.3	1.4	9	1.8	1.1	14	2.3	1.2	19	2.8	1.7
5	1.4	1.4	10	1.9	1.0	15	2.4	1.1	20	2.9	1.9

Таблица 1: Исходные данные выборки

2 Выполнение работы

2.1 Линейная регрессия

Пусть наблюдаемая случайная величина Z зависит от другой случайной величины X — значения последней мы можем наблюдать. Обозначим через $f(x)$ функцию, которая отражает зависимость среднего значения Z от X :

$$E[Z | X = x] = f(x)$$

Функция $f(t)$ называется *линией регрессии* Z на X , а уравнение $t = f(x)$ — *уравнением регрессии*.

Проведём $n = 20$ экспериментов и рассмотрим выборку $\vec{X} = (X_1, \dots, X_n)^T$, для неё получим значения наблюдаемой величины $\vec{Z} = (t_1, \dots, t_n)^T$.

Обозначим через ε_i разницу между наблюдаемой в i -м эксперименте случайной величиной и её математическим ожиданием:

$$\varepsilon_i = Z_i - E[Z | X = x_i] = Z_i - f(x_i)$$

По условию лабораторной функция $f(x)$ — **линейная регрессия**, и она имеет вид:

$$f(x) = \vec{\omega}^T \cdot \vec{\varphi}(x),$$

где:

- $\vec{\omega} = (\omega_0 \ \omega_1 \ \omega_2)^T$ — вектор неизвестных параметров (*коэффициенты линейной регрессии*);
- $\vec{\varphi}(x) = (1 \ x \ x^2)^T$ — вектор факторов регрессии.

То есть нашу модель можно записать в матричной форме:

$$\vec{Z} = \Phi^T \vec{\omega} + \vec{\varepsilon}, \tag{1}$$

где $\Phi(3 \times n)$ — *матрица плана* вида:

$$\Phi = (\vec{\varphi}(X_1) \ \vec{\varphi}(X_2) \ \dots \ \vec{\varphi}(X_n))$$

2.2 Метод наименьших квадратов

Метод наименьших квадратов (МНК) предполагает следующее:

$$\vec{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)^T \sim N_{0, \sigma^2}$$

Тогда функция правдоподобия для нашей выборки имеет вид:

$$\begin{aligned} f_{\vec{\omega}}(\vec{X}) &= \prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} \exp \left\{ -\frac{(Z_i - f(x_i))^2}{2\sigma^2} \right\} = \\ &= \frac{1}{\sigma^n (2\pi)^{n/2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (Z_i - f(x_i))^2 \right\} \end{aligned}$$

Оценкой метода наименьших квадратов (ОМНК) для неизвестных параметров $\vec{\omega}$ уравнения регрессии называется вектор параметров $\hat{\vec{\omega}}$, который доставляет минимум сумме квадратов отклонений.

Заметим, что при любом фиксированном σ^2 максимум функции правдоподобия достигается при наименьшем значении суммы квадратов отклонений:

$$\text{MSE} \equiv \sum_{i=1}^n (Z_i - f(x_i))^2 = \sum_{i=1}^n \varepsilon_i^2$$

Это равносильно минимизации квадрата евклидовой нормы вектора $\vec{\varepsilon}$:

$$\|\vec{\varepsilon}\|_2^2 = \sum_{i=1}^n \varepsilon_i^2 = \text{MSE}$$

Из вида модели (1) и по формуле скалярного произведения векторов:

$$\|\vec{\varepsilon}\|_2^2 = \left\| \vec{Z} - \Phi^T \vec{\omega} \right\|_2^2 = (\vec{Z} - \Phi^T \vec{\omega})^T (\vec{Z} - \Phi^T \vec{\omega})$$

Транспонируем произведение матриц и раскроем матричное произведение:

$$\begin{aligned} (\vec{Z} - \Phi^T \vec{\omega})^T (\vec{Z} - \Phi^T \vec{\omega}) &= (\vec{Z}^T - \vec{\omega}^T \Phi) (\vec{Z} - \Phi^T \vec{\omega}) = \\ &= \vec{Z}^T \vec{Z} - \vec{Z}^T \Phi^T \vec{\omega} - \vec{\omega}^T \Phi \vec{Z} + \vec{\omega}^T \Phi \Phi^T \vec{\omega} \end{aligned}$$

Заметим, что каждое слагаемое является скаляром. Из этого соображения транспонируем второе слагаемое, упростив выражение до вида:

$$\text{MSE} = \vec{Z}^T \vec{Z} - 2\vec{\omega}^T \Phi \vec{Z} + \vec{\omega}^T \Phi \Phi^T \vec{\omega}$$

Решим задачу минимизации выражения по вектору параметров $\vec{\omega}$. Найдём стационарные точки:

$$\begin{aligned} \frac{\partial \text{MSE}}{\partial \vec{\omega}} &= 0 - 2\Phi \vec{Z} + 2\Phi \Phi^T \vec{\omega} \\ \frac{\partial \text{MSE}}{\partial \vec{\omega}} = 0 &\implies \Phi \Phi^T \hat{\vec{\omega}} = \Phi \vec{Z} \implies \hat{\vec{\omega}} = (\Phi \Phi^T)^{-1} \Phi \vec{Z} \end{aligned} \quad (2)$$

Проверим достаточное условие существования экстремума в найденной стационарной точке. Для этого найдём матрицу Гессе:

$$H = \frac{\partial^2 \text{MSE}}{\partial \vec{\omega} \partial \vec{\omega}^T} = \frac{\partial}{\partial \vec{\omega}^T} (-2\Phi \vec{Z} + 2\Phi \Phi^T \vec{\omega}) = 2\Phi \Phi^T$$

Заметим, что Гессиан не зависит от вектора $\vec{\omega}$. Для существования минимума в точке $\hat{\vec{\omega}}$ нужно доказать его положительную определённую. По определению это значит следующее:

$$\vec{v}^T H \vec{v} > 0 \quad \forall \vec{v} \neq \vec{0}$$

Подставим наш Гессиан и выполним преобразования:

$$\vec{v}^T 2\Phi \Phi^T \vec{v} = 2(\vec{v}^T \Phi)(\Phi^T \vec{v}) = 2(\Phi^T \vec{v})^T (\Phi^T \vec{v}) = 2 \|\Phi^T \vec{v}\|_2^2 \geq 0$$

Если рассматривать лишь матрицы плана полного ранга (в нашем случае $\text{rank } \Phi = 3$), то неравенство становится строгим. Значит, H положительно определён, и $\hat{\vec{\omega}}$ является **точкой минимума**. $\square$

2.3 Вычисление оценки МНК

Вычислим матрицу плана Φ для выборки при помощи скрипта на Python с применением библиотеки Numpy для удобства матричных вычислений:

```
1 import numpy as np
2
3 X = np.array(task["x"])
4
5 def phi(x):
6     return [np.ones_like(x), x, x**2]
7
8 Phi = np.vstack(phi(X))
9
10 print(*Phi, sep='\n')
```

Листинг 1: Расчёт матрицы плана

Итого имеем:

i	$\varphi_0(X_i)$	$\varphi_1(X_i)$	$\varphi_2(X_i)$	i	$\varphi_0(X_i)$	$\varphi_1(X_i)$	$\varphi_2(X_i)$
1	1.0	1.0	1.0000	11	1.0	2.0	4.0000
2	1.0	1.1	1.2100	12	1.0	2.1	4.4100
3	1.0	1.2	1.4400	13	1.0	2.2	4.8400
4	1.0	1.3	1.6900	14	1.0	2.3	5.2900
5	1.0	1.4	1.9600	15	1.0	2.4	5.7600
6	1.0	1.5	2.2500	16	1.0	2.5	6.2500
7	1.0	1.6	2.5600	17	1.0	2.6	6.7600
8	1.0	1.7	2.8900	18	1.0	2.7	7.2900
9	1.0	1.8	3.2400	19	1.0	2.8	7.8400
10	1.0	1.9	3.6100	20	1.0	2.9	8.4100

Таблица 2: Матрица плана Φ в табличном виде

Заметим, что $\text{rank } \Phi = 3$, поэтому можем применить метод наименьших квадратов для поиска оценки неизвестных параметров $\hat{\omega}$ по формуле (2).

Воспользуемся следующим скриптом на Python для вычисления оценки:

```
1 Z = np.array(task["t"])
2
3 omega = np.linalg.inv(Phi @ Phi.T) @ Phi @ Z
4
5 print(omega)
```

Листинг 2: Расчёт ОМНК

Итого имеем:

$$\hat{\omega} = (4.94827296 \quad -3.93485988 \quad 0.98541809)^T$$

Таким образом, искомая линия регрессии имеет вид:

$$f(x) \approx 4.948 - 3.935x + 0.985x^2$$

2.4 Среднеквадратическое отклонение

Среднеквадратическое отклонение (СКО, или RMSE — Root Mean Square Error) σ случайной величины ξ определяется как квадратный корень от её дисперсии:

$$\sigma \equiv \sqrt{D[\xi]}$$

Нас интересует отклонение полученной линии регрессии от наблюдаемых случайных величин $\vec{Z}$ для данной выборки $\vec{X}$, поэтому рассмотрим СКО следующего вида:

$$\sigma^2 = D[\vec{Z} - f(\vec{X})] = D[\vec{\varepsilon}]$$

Получим оценку максимального правдоподобия $\hat{\sigma}^2$ из логарифмической функции правдоподобия для нашей выборки:

$$L_{\sigma^2}(\vec{X}) = \ln f_{\sigma^2}(\vec{X}) = -\frac{n}{2} \ln \sigma^2 - \frac{n}{2} \ln 2\pi - \frac{1}{2\sigma^2} \sum_{i=1}^n \varepsilon_i^2$$

Решим задачу максимизации выражения по параметру σ^2 . Найдём стационарные точки:

$$\begin{aligned} \frac{\partial L_{\sigma^2}(\vec{X})}{\partial(\sigma^2)} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n \varepsilon_i^2 \\ \frac{\partial L_{\sigma^2}(\vec{X})}{\partial(\sigma^2)} = 0 &\implies n\hat{\sigma}^2 = \sum_{i=1}^n \varepsilon_i^2 \implies \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \varepsilon_i^2 \end{aligned}$$

Проверим достаточное условие существования экстремума в найденной стационарной точке. Для этого найдём вторую производную:

$$\frac{\partial^2 L_{\sigma^2}(\vec{X})}{\partial(\sigma^2)^2} = \frac{\partial}{\partial(\sigma^2)} \left(-\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n \varepsilon_i^2 \right) = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{i=1}^n \varepsilon_i^2$$

Проверим знак производной в точке $\hat{\sigma}^2$:

$$\left. \frac{\partial^2 L_{\sigma^2}(\vec{X})}{\partial(\sigma^2)^2} \right|_{\sigma^2=\hat{\sigma}^2} = \frac{n}{2\hat{\sigma}^4} - \frac{n\hat{\sigma}^2}{\hat{\sigma}^6} = -\frac{n}{2\hat{\sigma}^4} < 0 \quad \square$$

Значит, $\hat{\sigma}^2$ является **точкой максимума**. $\square$

2.5 Вычисление оценки СКО

Вычислим оценку среднеквадратического отклонения $\hat{\sigma}$ при помощи скрипта на Python с применением библиотеки Numpy:

```
1 def f(x):
2     return omega.T @ phi(x)
3
4 n = X.shape[0]
5 epsilon = Z - f(X)
6 sigma_sq = np.sum(epsilon ** 2) / n
7 rmse = np.sqrt(sigma_sq)
```

```
8  
9 print (rmse)
```

Листинг 3: Расчёт оценки СКО

Итого имеем:

$$\hat{\sigma} \approx 0.0803965$$

2.6 График результата

Ниже изображён график полученной формулы линейной регрессии:

$$f(x) = 4.948 - 3.935x + 0.985x^2$$

Для сравнения результата с выборкой на график нанесены точки вида (X, Z) , которые соответствуют данным из исходной выборки.




Рис. 1: Результат линейной регрессии методом наименьших квадратов

3 Заключение