

ФГАОУ ВО «НИУ ИТМО»
ФАКУЛЬТЕТ ПРОГРАММНОЙ ИНЖЕНЕРИИ
И КОМПЬЮТЕРНОЙ ТЕХНИКИ

Лабораторная работа №5

Аппроксимация табличных данных:
задачи оптимизации и машинного обучения

(по дисциплине «Методы оптимизации»)

Выполнили:

Лабин Макар Андреевич,
МОПТ 3.3, Р3231, 466449;
Ожеховский Александр Сергеевич,
МОПТ 3.3, Р3231, 466944.

Проверил:

Запорожцев Иван Федорович



г. Санкт-Петербург, Россия
2026

Содержание

1	Задание	1
2	Аппроксимация функции	2
2.1	Эллиптический параболоид	2
2.1.1	Описание модели	2
2.1.2	Кривая обучения	3
2.1.3	Вектор невязки	4
2.1.4	Графики модели	4
2.1.5	Аналитический вид	5
2.2	Двумерная гауссиана	5
2.2.1	Описание модели	5
2.2.2	Кривая обучения	6
2.2.3	Вектор невязки	6
2.2.4	Графики модели	7
2.2.5	Аналитический вид	8
2.3	Константная модель	8
2.3.1	Аналитический вид	8
2.3.2	Вектор невязки	8
2.4	RBF-сеть	9
2.4.1	Описание модели	9
2.4.2	Начальное приближение	9
2.4.3	Градиент функции ошибки	11
2.4.4	Кривая обучения	11
2.4.5	Вектор невязки	12
2.4.6	Графики модели	13
2.4.7	Аналитический вид	14

1 Задание

В рамках выполнения лабораторной работы по варианту №6 необходимо выполнить следующие задачи:

1. Выполните аппроксимацию функции двух переменных, заданную таблично, с помощью эллиптического параболоида и двумерной гауссианы.
 - используйте *среднеквадратичную ошибку (MSE)* в качестве функции потерь;
 - постройте кривую обучения (*функцию потерь, которая зависит от номера итерации*);
 - вычислите невязки на каждом объекте для модельной функции;
 - отрисуйте модельную поверхность и её линии уровня вместе с точками данных по варианту;
 - запишите аналитический вид полученной модели.
2. Найдите лучшую аппроксимацию функции константной моделью:
 - в смысле минимизации среднеквадратичной ошибки (*MSE*);
 - в смысле минимизации средней абсолютной ошибки (*MAE*).
3. Выполните следующие вычисления *вручную* для аппроксимации функции RBF-сетью:
 - поиск центров;
 - задание начального приближения для градиентного спуска;
 - расчёт частных производных на первой итерации:
$$\frac{\partial L}{\partial c_2} \quad \frac{\partial L}{\partial \sigma_2} \quad \frac{\partial L}{\partial \omega_0} \quad \frac{\partial L}{\partial \omega_1}$$
4. Выполните аппроксимацию функции RBF-сетью:
 - постройте кривую обучения (*среднеквадратичная ошибка в качестве функции потерь*);
 - вычислите невязки на каждом объекте для модельной функции;
 - отрисуйте модельную поверхность и её линии уровня вместе с точками данных по варианту;
 - запишите аналитический вид полученной модели.

x	y	z
0.88	1.14	-0.1
1.92	1.95	1.72
2.85	3.04	4.73
3.88	4.12	2.27
5.02	5.03	0.03

Таблица 1: Данные функции, которая задана таблично.

2 Аппроксимация функции

2.1 Эллиптический параболоид

2.1.1 Описание модели

Эллиптический параболоид — это поверхность второго порядка, которая описывается функцией следующего вида:

$$z(x, y) = \frac{\tilde{x}^2}{a^2} + \frac{\tilde{y}^2}{b^2} + z_0, \quad a, b > 0$$

где:

$$\begin{pmatrix} \tilde{x} \\ \tilde{y} \end{pmatrix} = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix} \cdot \begin{pmatrix} x - x_0 \\ y - y_0 \end{pmatrix}$$

Параметры функции:

- a, b — коэффициенты, определяющие скорость «раскрытия» параболоида вдоль повернутых осей;
- x_0, y_0 — координаты вершины параболоида;
- θ — угол поворота главных осей параболоида относительно осей x и y ;
- z_0 — вертикальное смещение вершины по оси z .

Для упрощения анализа целесообразно перейти от геометрических параметров к общему алгебраическому виду поверхности второго порядка в неканонической системе координат.

Раскроем выражения для $\tilde{x}$ и $\tilde{y}$ через матрицу поворота и подставим их в исходное уравнение параболоида:

$$z(x, y) = \frac{((x - x_0) \cos \theta + (y - y_0) \sin \theta)^2}{a^2} + \frac{(-(x - x_0) \sin \theta + (y - y_0) \cos \theta)^2}{b^2} + z_0$$

После возведения в квадрат и группировки слагаемых при квадратичных и перекрестных членах, уравнение принимает вид, представленный на слайде:

$$z(x, y) = A(x - x_0)^2 + B(y - y_0)^2 + C(x - x_0)(y - y_0) + z_0$$

Где новые коэффициенты A, B, C связаны с исходными параметрами следующим образом:

- $A = \frac{\cos^2 \theta}{a^2} + \frac{\sin^2 \theta}{b^2}$
- $B = \frac{\sin^2 \theta}{a^2} + \frac{\cos^2 \theta}{b^2}$
- $C = \sin(2\theta) \left(\frac{1}{a^2} - \frac{1}{b^2} \right)$

Имеем задачу регрессии, которая заключается в минимизации среднеквадратичной ошибки:

$$\begin{aligned} Loss &= L(\{x_i, y_i, z_i\}_{i=1}^N, A, B, C, z_0, x_0, y_0) = MSE = \\ &= \frac{1}{2 \cdot N} \sum_{i=1}^N (z_i - z(x_i, y_i))^2 \rightarrow \min_{A, x_0, y_0, \sigma_x, \sigma_y, z_0, \theta} \end{aligned}$$

В текущей задаче можно было бы воспользоваться алгоритмами для линейной регрессии. Однако в рамках лабораторной работы рассмотрим более универсальный алгоритм L-BFGS-B.

L-BFGS-B (*Limited-memory Broyden–Fletcher–Goldfarb–Shanno with Boundaries*) — это итерационный квазиньютоновский метод оптимизации, который предназначен для поиска локального минимума функции при наличии ограничений на значения параметров:

- В отличие от классического метода Ньютона, L-BFGS-B не требует прямого вычисления гессиана. Вместо этого алгоритм аппроксимирует кривизну поверхности, анализируя изменения градиента на предыдущих итерациях.
- Алгоритм «ограничен по памяти». Он не хранит полную матрицу аппроксимации гессиана, а использует лишь несколько последних векторов изменений параметров и градиентов. Это делает метод пригодным для задач с большим количеством переменных.
- Использование формулы обновления Бройдена — Флетчера — Гольдфарба — Шанно обеспечивает сверхлинейную сходимость, что эффективнее простого градиентного спуска.
- Поддержка ограничений позволяет задавать допустимые интервалы для каждого параметра. В данной задаче это необходимо для соблюдения физического смысла.

2.1.2 Кривая обучения




Рис. 1: Кривая обучения для эллиптического параболоида (*L-BFGS-B*).

2.1.3 Вектор невязки




Рис. 2: Невязки исходных объектов для эллиптического параболоида.

2.1.4 Графики модели




Рис. 3: Модельная поверхность эллиптического параболоида после обучения.




Рис. 4: Линии уровня эллиптического параболоида после обучения.

2.1.5 Аналитический вид

В результате обучения модель имеет следующий вид:

$$z(x, y) = 1.739(x - 3.547)^2 + -2.000(y - 3.399)^2 + -0.991(x - 3.547)(y - 3.399) + 3.772$$

2.2 Двумерная гауссиана

2.2.1 Описание модели

Двумерная гауссиана — это нелинейная функция следующего вида:

$$z(x, y) = A \cdot \exp \left(- \left[\frac{\tilde{x}^2}{2\sigma_x^2} + \frac{\tilde{y}^2}{2\sigma_y^2} \right] \right) + z_0$$

где:

$$\begin{pmatrix} \tilde{x} \\ \tilde{y} \end{pmatrix} = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix} \cdot \begin{pmatrix} x - x_0 \\ y - y_0 \end{pmatrix}$$

Параметры функции:

- A — амплитуда (*высота пика относительно уровня смещения*);
- x_0, y_0 — координаты центра функции;
- σ_x, σ_y — среднеквадратичные отклонения вдоль поворнутых осей;
- θ — угол поворота гауссианы относительно осей x и y ;
- z_0 — константное смещение поверхности.

Имеем задачу регрессии, которая заключается в минимизации среднеквадратичной ошибки:

$$\begin{aligned} Loss &= L(\{x_i, y_i, z_i\}_{i=1}^N, A, z_0, \sigma_x, \sigma_y, x_0, y_0, \theta) = MSE = \\ &= \frac{1}{2 \cdot N} \sum_{i=1}^N (z_i - z(x_i, y_i))^2 \rightarrow \min_{A, x_0, y_0, \sigma_x, \sigma_y, z_0, \theta} \end{aligned}$$

Можно заметить, что перед нами также нелинейная регрессия. Аналогично воспользуемся алгоритмом L-BFGS-B.

2.2.2 Кривая обучения




Рис. 5: Кривая обучения для двумерной гауссианы (*L-BFGS-B*).

2.2.3 Вектор невязки




Рис. 6: Невязки исходных объектов для двумерной гауссианы.

2.2.4 Графики модели




Рис. 7: Модельная поверхность двумерной гауссианы после обучения.




Рис. 8: Линии уровня двумерной гауссианы после обучения.

2.2.5 Аналитический вид

В результате обучения модель имеет следующий вид:

$$z(x, y) = 7.221 \cdot \exp \left(- \left[\frac{\tilde{x}^2}{2 \cdot 1.161^2} + \frac{\tilde{y}^2}{2 \cdot 0.971^2} \right] \right) + 3.772$$

где:

$$\begin{pmatrix} \tilde{x} \\ \tilde{y} \end{pmatrix} = \begin{pmatrix} \cos(-0.495) & \sin(-0.495) \\ -\sin(-0.495) & \cos(-0.495) \end{pmatrix} \cdot \begin{pmatrix} x - (3.635) \\ y - (2.654) \end{pmatrix}$$

2.3 Константная модель

2.3.1 Аналитический вид

Лучшая константная модель в смысле минимизации среднеквадратичной ошибки (MSE) — среднее выборочное:

$$\hat{z} = \bar{z} = \frac{1}{n} \sum_{i=1}^n z_i = 1.730000$$

Лучшая константная модель в смысле минимизации средней абсолютной ошибки (MAE) — медиана:

$$\hat{z} = \text{median}(z_1, \dots, z_n) = \begin{cases} z_{((n+1)/2)}, & 2 \nmid n \\ \frac{1}{2} (z_{(n/2)} + z_{(n/2+1)}), & 2 \mid n \end{cases} = 1.720000$$

2.3.2 Вектор невязки




Рис. 9: Невязки исходных объектов для константной модели (MSE).




Рис. 10: Невязки исходных объектов для константной модели (MAE).

2.4 RBF-сеть

2.4.1 Описание модели

RBF-сеть — это модель в виде графа, у которого вершины группируются в 3 «слоя»: входной, скрытый (*слой базисных функций*) и выходной.

Входных нейронов два — моделируем функцию двух переменных $z = z(x, y)$. Так как данных мало, используется сеть с двумя «скрытыми нейронами» (*двумя слагаемыми РБФ*):

$$z(x, y) = w_1 e^{-\frac{(x-c_{1x})^2 + (y-c_{1y})^2}{2\sigma_1^2}} + w_2 e^{-\frac{(x-c_{2x})^2 + (y-c_{2y})^2}{2\sigma_2^2}} + w_0$$

Параметры функции:

- $c_1 = (c_{1x}, c_{1y})^T, c_2 = (c_{2x}, c_{2y})^T \in \mathbb{R}^2$ — центры (*centers*);
- $\sigma_{1,2} \in \mathbb{R}_+$ — параметры ширины (*widths*);
- $w = (w_0, w_1, w_2)^T \in \mathbb{R}^3$ — веса (*weights*);

Имеем задачу регрессии, которая заключается в минимизации среднеквадратичной ошибки:

$$\begin{aligned} Loss &= L(\{x_i, y_i, z_i\}_{i=1}^N, c_1, c_2, \sigma_1, \sigma_2, w) = MSE = \\ &= \frac{1}{2 \cdot N} \sum_{i=1}^N (z_i - z(x_i, y_i))^2 \rightarrow \min_{A, x_0, y_0, \sigma_x, \sigma_y, z_0, \theta} \end{aligned}$$

2.4.2 Начальное приближение

Определим начальное приближение при помощи *метода K-средних*.

На нулевой итерации выберем в качестве центров $c_1^{(0)}$, $c_2^{(0)}$ два случайных объекта:

$$c_1^{(0)} = c_2^{(0)} =$$

В начале следующей (*первой*) итерации для каждого объекта считаем расстояние до каждого центра (*допустим, Евклидово*). Если объект ближе к центру c_i , то приписываем его к кластеру C_i :

x_i	$\ x_i - c_1\ _2$	$\ x_i - c_2\ _2$	C_i
x_1	d_{11}	d_{12}	C_1 / C_2
x_2	d_{21}	d_{22}	C_1 / C_2
x_3	d_{31}	d_{32}	C_1 / C_2
x_4	d_{41}	d_{42}	C_1 / C_2
x_5	d_{51}	d_{52}	C_1 / C_2

Таблица 2: Распределение объектов по кластерам на первой итерации.

После заполнения кластеров определяем их центры как среднее арифметическое векторов-элементов:

i	C_i	$c_i^{(1)}$
1	$\{x_1, x_2, x_4\}$	
2	$\{x_3, x_5, x_6\}$	

Таблица 3: Пересчитанные центры кластеров после первой итерации

Проверим смещение центров относительно прошлого положения:

$$\begin{cases} \|c_1^{(1)} - c_1^{(0)}\|_2 = \dots < \varepsilon = \dots \\ \|c_2^{(1)} - c_2^{(0)}\|_2 = \dots < \varepsilon = \dots \end{cases}$$

Продолжим итерации, пока не выполнен критерий останова:

t	$c_1^{(t-1)}$	$c_2^{(t-1)}$	$C_1^{(t)}$	$C_2^{(t)}$	$c_1^{(t)}$	$c_2^{(t)}$	$\Delta_1^{(t)}$	$\Delta_2^{(t)}$
0			$\{\dots\}$	$\{\dots\}$				
1			$\{\dots\}$	$\{\dots\}$				
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
t	$c_1^{(t)}$	$c_2^{(t)}$	$\{\dots\}$	$\{\dots\}$	$c_1^{(t+1)}$	$c_2^{(t+1)}$	$\Delta_1^{(t)}$	$\Delta_2^{(t)}$

Таблица 4: Итерационный процесс кластеризации.

В итоге имеем следующее начальное приближение центров:

$$c_1 = \dots \quad c_2 = \dots$$

Начальное приближение для параметров ширины установим по формуле:

$$\sigma_1 = \sigma_2 = \frac{\|c_2 - c_1\|_2}{2} = \dots$$

Вектор весов определим как $w^{(0)} = 0.1 \cdot \{\xi_i\}_{i=1}^3$, где $\xi_i \sim \mathcal{N}(0, 1)$:

$$w^{(0)} = \dots$$

2.4.3 Градиент функции ошибки

Обозначим значение j -й базисной функции для i -го объекта:

$$G_{ij} = e^{-\frac{(x_i - c_{jx})^2 + (y_i - c_{jy})^2}{2\sigma_j^2}}$$

Вычислим градиент целевой функции покомпонентно:

$$\frac{\partial L}{\partial w_0} = -\frac{1}{N} \sum_{i=1}^N (z_i - z(x_i, y_i))$$

$$\frac{\partial L}{\partial w_j} = -\frac{1}{N} \sum_{i=1}^N (z_i - z(x_i, y_i)) \cdot G_{ij}, \quad j \in \{1, 2\}$$

$$\frac{\partial L}{\partial c_{jx}} = -\frac{1}{N} \sum_{i=1}^N (z_i - z(x_i, y_i)) \cdot w_j G_{ij} \cdot \frac{(x_i - c_{jx})}{\sigma_j^2}$$

$$\frac{\partial L}{\partial c_{jy}} = -\frac{1}{N} \sum_{i=1}^N (z_i - z(x_i, y_i)) \cdot w_j G_{ij} \cdot \frac{(y_i - c_{jy})}{\sigma_j^2}$$

$$\frac{\partial L}{\partial \sigma_j} = -\frac{1}{N} \sum_{i=1}^N (z_i - z(x_i, y_i)) \cdot w_j G_{ij} \cdot \frac{(x_i - c_{jx})^2 + (y_i - c_{jy})^2}{\sigma_j^3}$$

Для первой итерации имеем следующие значения компонент градиента:

$$\omega^{(1)} = (\dots)^T$$

2.4.4 Кривая обучения




Рис. 11: Кривая обучения для RBF-сети.

2.4.5 Вектор невязки




Рис. 12: Невязки исходных объектов для RBF-сети.

2.4.6 Графики модели




Рис. 13: Модельная поверхность RBF-сети после обучения.




Рис. 14: Линии уровня RBF-сети после обучения.

2.4.7 Аналитический вид

В результате обучения модель имеет следующий вид:

$$z(x, y) = 5.049e^{-\frac{(x-2.985)^2 + (y-3.112)^2}{2 \cdot 1.155^2}} + -0.382e^{-\frac{(x-4.635)^2 + (y-4.723)^2}{2 \cdot 0.143^2}} + -0.279$$