

ФГАОУ ВО «НИУ ИТМО»
ФАКУЛЬТЕТ ПРОГРАММНОЙ ИНЖЕНЕРИИ
И КОМПЬЮТЕРНОЙ ТЕХНИКИ

Лабораторная работа №7

Методы оптимизации в нейросетевых вычислениях

(по дисциплине «Методы оптимизации»)

Выполнили:

Лабин Макар Андреевич,
МОПТ 3.3, Р3231, 466449;
Ожеховский Александр Сергеевич,
МОПТ 3.3, Р3231, 466944.

Проверил:

Запорожцев Иван Федорович



г. Санкт-Петербург, Россия
2026

Содержание

1	Задание	1
2	Выполнение работы	2
2.1	Анализ функции	2
2.1.1	Седловые точки	2
2.1.2	Глобальный минимум	2
2.1.3	Линии уровня	3
2.1.4	Потенциальные сложности оптимизации	4
2.2	Сравнение алгоритмов машинного обучения	5
2.2.1	Градиентный спуск	5
2.2.2	Алгоритм Adam	5
2.2.3	Подбор коэффициентов Adam	6
2.2.4	Эталонная реализация Adam	8

1 Задание

В рамках выполнения лабораторной работы *по варианту №6* необходимо выполнить следующие задачи:

1. Исследуйте функцию нескольких переменных $f(x, y) = 10^{-2}(8x^2 + 2xy + 43x + 10y + 15)$ в области $\mathcal{D} = [-20, 20] \times [-50, 50]$ аналитически и программно:
 - определите все седловые точки, проведите исследование на локальные экстремумы (*укажите все или докажите, что их нет*);
 - найдите глобальный минимум функции;
 - напишите программный модуль на языке Python для построения линий уровня этой функции;
 - сделайте выводы, какие сложности для оптимизационного алгоритма могут возникнуть в случае такой функции.
2. Реализуйте и исследуйте алгоритмы градиентного спуска и эвристику **Adam** для задачи преодоления седловой точки.
 - выберите начальное приближение, скорость обучения и критерий останова так, чтобы последовательные приближения стандартного градиентного спуска сходились к седловой точке за ≈ 100 итераций, зафиксируйте эти параметры и постройте визуализацию линий уровня и траектории;
 - реализуйте программно на языке Python эвристику по варианту — метод **Adam** — и с его помощью за то же количество итераций получите последовательность приближений, которая «преодолеывает» седловую точку;
 - подберите область отображения для эффективной иллюстрации диаграммы последовательных приближений и, не меняя её, найдите значения гиперпараметров для двух случаев:
 - когда явно просматривается пилообразное движение в стороны от направления к глобальному минимуму;
 - когда направление движения более чёткое и без колебаний.
 - используйте готовую реализацию алгоритма **Adam** (*рекомендуется библиотека PyTorch*) для подтверждения успешного решения задачи «преодоления» седловой точки и постройте один вариант визуализации диаграммы приближений в той же области.

2 Выполнение работы

2.1 Анализ функции

2.1.1 Седловые точки

Рассмотрим функцию двух переменных:

$$f(x, y) = 10^{-2}(8x^2 + 2xy + 43x + 10y + 15)$$

Это квадратичная функция, которая определена в заданной области $\mathcal{D}$. Исследуем её на наличие *седловых точек* — стационарных точек, которые не являются точками экстремума.

По необходимому условию экстремума второго порядка для точки (x, y) :

$$\begin{cases} \frac{\partial f}{\partial x}(x, y) = 0 \\ \frac{\partial f}{\partial y}(x, y) = 0 \end{cases} \implies \begin{cases} 10^{-2}(16x + 2y + 43) = 0 \\ 10^{-2}(2x + 10) = 0 \end{cases} \implies \begin{cases} x = -5 \\ y = 18.5 \end{cases}$$

Точка $M = (-5, 18.5) \in \mathcal{D}$, поэтому продолжим её исследование. Для проверки достаточного условия найдём матрицу Гессе:

$$H = \begin{pmatrix} \frac{\partial^2 f}{\partial x^2}(x, y) & \frac{\partial^2 f}{\partial x \partial y}(x, y) \\ \frac{\partial^2 f}{\partial y \partial x}(x, y) & \frac{\partial^2 f}{\partial y^2}(x, y) \end{pmatrix} = 10^{-2} \cdot \begin{pmatrix} 16 & 2 \\ 2 & 0 \end{pmatrix}$$

Заметим, что определитель постоянный для M . Имеем ситуацию:

$$\Delta_1 = 16 \cdot 10^{-2} \quad \Delta_2 = -4 \cdot 10^{-4}$$

Поскольку $\Delta_2 < 0$, то точка M не является точкой экстремума. Это значит, что она *седловая по определению*. Для полноты описания приведём значение функции в данной точке:

$$f(M) = 0$$

2.1.2 Глобальный минимум

Функция рассматривается в области $\mathcal{D}$, которая является компактом (*она замкнута и ограничена*). Поскольку $f \in C(\mathcal{D})$, по теореме Вейерштрасса о функции на компакте f достигает своего наименьшего значения.

Как выяснилось в предыдущем разделе, у функции нет точек экстремума в области $\mathcal{D}$. Поэтому исследуем границы области и найдём глобальный минимум:

1. Точка лежит на *левой* стороне прямоугольника ($x = -20, y \in [-50, 50]$):

$$f_1(y) = 10^{-2}(2355 - 30y)$$

Функция f_1 линейна относительно y . Она убывает, поэтому минимум достигается в точке $y = 50$:

$$f_1(50) = 10^{-2}(2355 - 1500) = 8.55$$

2. Точка лежит на *правой* стороне квадрата ($x = 20, y \in [-50, 50]$):

$$f_2(y) = 10^{-2}(4075 + 50y)$$

Функция f_2 линейна относительно y . Она возрастает, поэтому минимум достигается в точке $y = -50$:

$$f_2(-50) = 10^{-2}(4075 - 2500) = 15.75$$

3. Точка лежит на *верхней* стороне квадрата ($x \in [-20, 20], y = 50$):

$$f_3(x) = 10^{-2}(8x^2 + 143x + 515)$$

Это квадратичная функция, у которой ветви направлены вверх, так как $8 \cdot 10^{-2} > 0$. Следовательно, минимум лежит на вершине параболы:

$$x_{\text{в}} = -\frac{143}{16} \in [-20, 20] \implies f_3(x_{\text{в}}) = -1.2403125$$

4. Точка лежит на *нижней* стороне прямоугольника ($x \in [-20, 20], y = -50$):

$$f_4(x) = 10^{-2}(8x^2 - 57x - 485)$$

Это квадратичная функция, у которой ветви направлены вверх, так как $8 \cdot 10^{-2} > 0$. Следовательно, минимум лежит на вершине параболы:

$$x_{\text{в}} = \frac{57}{16} \in [-20, 20] \implies f_4(x_{\text{в}}) = -5.8653125$$

После рассмотрения границ можно сделать вывод, что на нижней стороне области $\mathcal{D}$ лежит глобальный минимум области:

$$\arg \min_{(x,y) \in \mathcal{D}} f(x,y) = \left(\frac{57}{16}, -50 \right) \implies f\left(\frac{57}{16}, -50 \right) = -5.8653125$$

2.1.3 Линии уровня

Ниже изображены линии уровня данной по варианту функции $f(x)$. Белым отмечена найденная седловая точка M в области $\mathcal{D}$, а красным — точка глобального минимума.




Рис. 1: Линии уровня $f(x)$ с седловой точкой M .

2.1.4 Потенциальные сложности оптимизации

Если воспользоваться численными методами первого порядка для оптимизации $f(x)$ в области $\mathcal{D}$, то могут возникнуть следующие трудности:

- Поверхность имеет ярко выраженный «овражный» характер. Значит, градиентный спуск может совершать резкие поперечные колебания (*пилообразное движение*), что замедляет поиск решения.
- Слишком малая скорость обучения сделает движение вдоль пологого «дна» оврага чрезвычайно медленным, что потребует огромного числа итераций.
- Классический градиентный спуск может застрять в окрестности седловой точки, так как градиент $\nabla f \approx 0$.
- В зависимости от начального приближения алгоритм может сойтись к локальному минимуму на другой стороне прямоугольника.

2.2 Сравнение алгоритмов машинного обучения

2.2.1 Градиентный спуск

Воспользуемся такими параметрами для *стандартного градиентного спуска*:

- начальное приближение — $(12.0, 20.6)^T$;
- скорость обучения — 0.71;
- ограничение по итерациям — 150;
- малая константа ε — 0.00002.

Программно в качестве критерия останова выбрана малость нормы градиента и малость нормы разности приближений:

$$\|\nabla f(x^{(k)}, y^{(k)})\| < \varepsilon \quad \text{или} \quad \|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| < \varepsilon$$

Получаем следующий график градиентного спуска за 99 итераций:




Рис. 2: Диаграмма последовательных приближений градиентного спуска.

2.2.2 Алгоритм Adam

Алгоритм Adam (*Adaptive Momentum*) — метод стохастической оптимизации, который сочетает в себе идеи из алгоритмов Adagrad (*Adaptive Gradient*) и RMSProp (*Root Mean Square Propagation*).

В нём фигурируют понятия моментов первого и второго порядков из математической статистики:

- момент первого порядка $m^{(t)}$ приближает *математическое ожидание* градиента;
- момент второго порядка $v^{(t)}$ приближает *дисперсию* градиента.

Правда, вместо стандартной формулы, которая была представлена на курсе математической статистики, используется *простое экспоненциальное сглаживание*:

$$\begin{aligned} m^{(t)} &= \beta_1 m^{(t-1)} + (1 - \beta_1) g^{(t)} \\ v^{(t)} &= \beta_2 v^{(t-1)} + (1 - \beta_2) (g^{(t)})^2 \end{aligned}$$

где $g^{(t)} = \nabla_{\mathbf{x}} f(\mathbf{x}^{(t)})$ — градиент целевой функции на шаге t , а гиперпараметры $\beta_1, \beta_2 \in [0, 1)$ управляют экспоненциальным сглаживанием. На практике чаще всего используют значения $\beta_1 = 0.9$ и $\beta_2 = 0.99$.

Можно убедиться, что коэффициенты в сумме равны единице при $t \rightarrow \infty$:

$$(1 - \beta_1) \sum_{k=0}^{\infty} \beta_1^k = (1 - \beta_1) \cdot \frac{1}{1 - \beta_1} = 1$$

Однако в конечном случае ($t < \infty$) коэффициенты оказываются смещены в сторону нуля (*недобор*):

$$(1 - \beta_1) \sum_{k=0}^{t-1} \beta_1^k = (1 - \beta_1) \cdot \frac{1 - \beta_1^t}{1 - \beta_1} = 1 - \beta_1^t$$

Чтобы компенсировать это, на каждом шаге вычисляем несмещённые оценки моментов (*bias-corrected estimates*), то есть нормализуем величины:

$$\hat{m}^{(t)} = \frac{m^{(t)}}{1 - \beta_1^t}, \quad \hat{v}^{(t)} = \frac{v^{(t)}}{1 - \beta_2^t}$$

Правило обновления параметров модели $\mathbf{x}$ выглядит так:

$$\mathbf{x}_i^{(t+1)} = \mathbf{x}_i^{(t)} - \frac{\eta}{\sqrt{\hat{v}_i^{(t)}}} \hat{m}_i^{(t)}$$

где η — базовая скорость обучения.

Идеологически это можно интерпретировать так:

- $\hat{m}^{(t)}$ отвечает за направление движения;
- $\sqrt{\hat{v}}$ отвечает за масштаб шага.

2.2.3 Подбор коэффициентов Adam

Воспользуемся такими параметрами, чтобы воспроизвести ситуацию с *пилообразным движением* в стороны:

- начальное приближение — $(12.0, 20.6)^T$;
- базовая скорость обучения — 0.95;

- скорость обучения момента первого порядка — 0.92;
- скорость обучения момента второго порядка — 0.4;
- ограничение по итерациям — 99;
- малая константа ε — 0.00001.

Как и в случае с градиентным спуском в качестве критерия останова выбрана малость нормы градиента и малость нормы разности приближений:

$$\|\nabla f(x^{(k)}, y^{(k)})\| < \varepsilon \quad \text{или} \quad \|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| < \varepsilon$$

Получаем следующий график алгоритма Adam за 99 итераций:




Рис. 3: Диаграмма последовательных пилообразных приближений Adam.

Воспользуемся такими параметрами, чтобы воспроизвести ситуацию с *плавным движением*:

- начальное приближение — $(12.0, 20.6)^T$;
- базовая скорость обучения — 0.99;
- скорость обучения первого момента — 0.4;
- скорость обучения второго момента — 0.95;
- ограничение по итерациям — 99;

- малая константа ε — 0.00001.

Получаем следующий график алгоритма Adam за 99 итераций:




Рис. 4: Диаграмма последовательных плавных приближений Adam.

2.2.4 Эталонная реализация Adam

Воспользуемся реализацией алгоритма Adam из библиотеки *PyTorch* и воспроизведём ситуацию с *плавным движением*:




Рис. 5: Диаграмма последовательных приближений Adam (PyTorch).